


Compagnon immobilier

Rapport final



Le 29/05/25

Sami Bouchaaboun
Jean-Michel Lievin
Mathieu Pitkevicht

[Introduction](#)

[Exploration des données](#)

[Dataset ventes immobilières \(68\)](#)

[Dataset locations immobilières \(68\)](#)

[Dataset valeurs foncières \(data-gouv\)](#)

[Data Visualisations - annonces ventes et locations 68](#)

- [Dataset ventes → Lien vers graphes Plotly : dataviz_sales_68.ipynb](#)
- [Dataset locations → Lien vers graphes Plotly : dataviz_rents_68.ipynb](#)

[Data Visualisations - valeurs foncières \(data-gouv\)](#)

[Pre-processing](#)

[Modélisation](#)

[Modélisation du prix de vente au m2](#)

[Interprétation des modèles](#)

[Modélisation de l'évolution du prix de vente](#)

[Ressources](#)

Introduction

Description du projet

Notre projet vise à développer une solution basée sur des algorithmes de machine learning, et dans la mesure du possible du deep learning, pour accompagner les acheteurs de biens immobiliers dans leur prise de décision. Cette solution permettra d'explorer, comparer et évaluer différents territoires à partir de données hétérogènes liées aux prix de l'immobilier, à la démographie, aux infrastructures de transport, aux services de proximité, à l'éducation, à la criminalité et aux indicateurs socio-économiques.

L'application devra intégrer des modules de data visualisation avancée, facilitant la comparaison multicritère des territoires, la mise en évidence de leurs atouts et faiblesses respectifs, ainsi que la génération de classements dynamiques selon les préférences de l'utilisateur.

Objectifs du projet

Deux objectifs de modélisation supervisée sont identifiés :

1. Prévoir l'évolution des prix immobiliers à moyen terme, en fonction de caractéristiques territoriales, économiques et temporelles, dans une logique de projection.
2. Estimer la valeur au m² d'un bien immobilier donné, à partir de ses attributs structurés (surface, localisation, équipements, DPE, etc.) et, dans une seconde phase, à l'aide de données non structurées telles que les descriptions textuelles des annonces ou les photographies du bien.

L'objectif global est de transformer de grands volumes de données complexes en outils d'aide à la décision intelligibles et interactifs, afin de favoriser une évaluation personnalisée et éclairée des opportunités d'achat ou d'investissement pour les particuliers ou les professionnels du secteur.


Contexte

Depuis 2019, les prix de l'immobilier en France ont augmenté malgré un ralentissement récent, particulièrement dans les grandes villes. La hausse des taux d'intérêt a compliqué l'accès au crédit, réduisant le volume des transactions. Les disparités régionales sont importantes, avec des hausses marquées en zones urbaines et une stagnation voire une baisse dans les zones rurales. La pandémie a orienté la demande vers des biens spacieux en périphérie. Entre 2023 et 2024, le marché s'est ralenti avec une baisse des transactions et une stabilisation des prix.

La crise sanitaire du COVID-19 a bousculé les comportements d'achat avec une forte demande pour des espaces extérieurs et des bien situés en périphérie urbaine. Face à cette forte demande, les prix de l'immobilier ont subi une hausse significative.

Les contextes économiques comme l'inflation, le ralentissement de la croissance et l'augmentation des taux bancaires ont freiné les impulsions d'achats.


Taux des crédits nouveaux à l'habitat toutes durées



Source : Banque de France

Concernant le marché locatif en France, la demande de logements reste élevée. Plusieurs facteurs comme l'augmentation des loyers, la baisse de constructions de logements neufs, l'investissement dans du locatif saisonnier type AirBnB rendent l'accès à la location plus difficile.

Loyer moyen au mètre carré de surface habitable du parc locatif social en France au 1 janvier 2024, selon la région (en euros)



Sources

SDES; Ministère de la Transition écologique et de la Cohésion des territoires
© Statista 2025

Informations complémentaires:

France; SDES; 1 janvier 2019 – 1 janvier 2024

Exploration des données

Nous disposons de trois datasets bruts pour notre projet :

- un dataset sur les ventes immobilières du département 68 (Haut-Rhin)
- un dataset sur les locations immobilières du département 68
- un dataset des valeurs foncières géolocalisées des cinq dernières années de la France entière (exceptés les départements de la Moselle, du Bas-Rhin, du Haut-Rhin et de Mayotte).

Ces données sont disponibles librement aux liens suivants :

- https://raw.githubusercontent.com/klopstock-dviz/immo_vis/master/data/ech_annonces_ventes_68.csv
- https://raw.githubusercontent.com/klopstock-dviz/immo_vis/master/data/ech_annonces_locations_68.csv
- <https://www.data.gouv.fr/fr/datasets/demandes-de-valeurs-foncieres-geolocalisees/>

Dataset ventes immobilières (68)

nombre de lignes	27737
nombre de colonnes	58
nombre de doublons	0
manquants (%)	28.68
nombre de variables quantitatives	37
nombre de variables qualitatives	21

- **Plage temporelle des données**

Les données analysées couvrent la période de 2019 à 2023.

- **Premières observations**

Le jeu de données comporte certains noms de colonnes en lettres capitales. Il semble que ces données proviennent d'une application tierce conventionnées par le nom "IRIS". Les dernières colonnes après celles mentionnées montrent des valeurs calculées (taux, médianes, etc.).

La valeur cible qui nous intéresse est le champ "**prix_m2_vente**".

Le dataset présente beaucoup d'outliers et demande un travail d'investigation pour les comprendre.

Les valeurs ne sont ni normalisées, ni standardisées et devront l'être dans la prochaine étape de pré-processing

Les noms des colonnes pourraient être homogénéisée (snake_case)

Le nombre de données concernant la vente est croissante de 2020 à 2022. Il y a une forte diminution en 2023.

Les identifiants sont une concaténation du nom de l'agence et d'un identifiant unique

- **Analyse des outliers**

Pour le champ "**charges_copro**", la médiane est estimée à 1200, tandis qu'une valeur aberrante isolée a été détectée, probablement liée à une erreur de saisie.

Pour le champ "**étage**", il y a des valeurs négatives et une valeur à 999. Ces valeurs ne semblent concerner que les appartements

Pour les *étages -1* une hypothèse pour des souplex ou sous-sols aménagés, la décote varie entre 15 et 30 % selon l'emplacement

Pour les *étages 999* ces biens semblent être regroupés dans des zones géographiques précises

Pour le champ "**annee_construction**", nous avons une année à 971. C'est un cas isolé et semble être une erreur de saisie avec 1971. Des recherches avant la médiane des années du quartier conforte cette hypothèse.

Le champ "**nb_logements_copro**" comporte des valeurs extrêmes mais non aberrantes. Le 1^{er} cas représente une zone spécifique. Le 2^e cas représente un bâtiment de 19 étages.

Le champ "**dpeC**" comporte des valeurs extrêmes également. Une recherche avec des indices de performance énergétique et les systèmes de chauffage démontre une cohérence entre ces valeurs.

Le champ "**nb_toilettes**" comporte quelques valeurs élevées. Un rapprochement avec le "**TYP_IRIS_x**" démontre une zone spécifique (Z). Une hypothèse serait de considérer un bien avec des sanitaires collectifs ou autre.

Le champ "**nb Terraces**" comporte une valeur extrême. C'est un cas isolé et le nombre de pièces à vivre est cohérent avec le nombre de terrasses.

Pour le champ "**places_parking**" seulement une valeur semble aberrante, la surface et le type de bien ne justifient pas cette valeur.

Le champ "**nb_pieces**" comporte une incohérence, la surface n'est pas en adéquation avec le nombre de pièces.

Le champ "**surface_balcon**" comporte une valeur aberrante. La surface du balcon est supérieure à la surface du bien. Cela semble être une erreur de saisie.

Pour le champ **“surface”** il est difficile d’avoir une interprétation pour des biens situés dans des zones spécifiques.

Pour le champ **“surface_terrain”**, il y a des valeurs extrêmes. Il peut s'agir de bois ou de terrain agricole dépendant du bien. Pour la plus grande valeur, Google Maps nous montre l'emplacement d'un bois.

Pour le champ **“prix_bien”**, les prix sont cohérents avec la surface et le nombre de pièces.

Les champs **“prix_maison”** et **“prix_terrain”** ne contiennent pas de valeurs aberrantes.

Le champ **“mensualiteFinance”** contient deux valeurs extrêmes qui concernent des ventes en cours.

Pour le champ **“prix_m2_vente”**, certaines surfaces sont anormalement petites par rapport aux prix au m².

Le champ **“duree_int”** est difficile à interpréter. Il peut s'agir d'un champ calculé et nous ne savons pas exactement quelle durée est prise en compte.

- **Corrélations potentielles**

Une relation semble se dessiner entre le prix d'un bien, le prix de la maison, le prix, du terrain, sa surface, et le nombre de pièces.

Une matrice de corrélation fait ressortir les champs suivants: **“prix_maison”**, **“prix_bien”**, **“prix_terrain”**, **“annee_construction”**, **“mapCoordonneesLongitude”** et **“dpeC”**

- **Terminologies**

Un IRIS (Îlot Regroupé pour l'Information Statistique) est une unité géographique utilisée pour des analyses statistiques et démographiques détaillées. Créé par l'INSEE (Institut National de la Statistique et des Études Économiques), un IRIS constitue la division infra-communale la plus fine pour diffuser des données publiques tout en respectant la confidentialité.

“GRD_QUART” : Ce champ représente le numéro de grand quartier. Il est composé du code du département, suivi du numéro de commune ou du numéro d'arrondissement municipal (pour des villes comme Paris, Lyon et Marseille), et enfin du numéro du grand quartier

“UU2010” : Ce champ désigne les unités urbaines selon le découpage de 2010. Il inclut un code du département (ou "00" pour les unités urbaines qui s'étendent sur plusieurs départements ou au-delà des frontières), suivi d'un code indiquant la taille de la population, puis d'un numéro d'ordre à l'intérieur de cette taille

- **Disponibilité des variables**

Disponibilité variable	Nombre de variables	Exemples
Variables disponibles à 100%	29	etage, surface, prix_bien, nb_pieces, balcon, eau, bain, idannonce...
Variables disponibles entre 50% et 100%	12	logement_neuf, duree_int, ges_class, loyer_m2_median_n7, nb_toilettes
Variables disponibles entre 25% et 50%	10	chauffage_mode, cave, surface_terrain, places_parking
Variables disponibles entre 0% et 25%	7	parking, videophone, prix_terrain, prix_maison, surface_balcon
total	59	

- **Type des variables**

type variable	Nombre de variables	Exemples
float	22	charges_copro, loyer_m2_median, prix_maison, prix_terrain
integer	15	bain, balcon, code_iris, eau, etage
object	22	annonce_exclusive, ascenseur, cave, typedebien, exposition
total	59	

- **Gestion des NAs**

Actions	Concernées	Exemples
Rien à faire	variables sans NA	
Supprimer la colonne	variables int/flt avec taux de NA $\leq$ X%	
imputation (moyenne, mediane)	variables int/flt avec taux de NA $>$ X%	
creation d'une catégorie missing	variables categorielles	

Dataset locations immobilières (68)

nombre de lignes	11702
nombre de colonnes	51
nombre de doublons	0
manquants (%)	29.69
nombre de variables quantitatives	31
nombre de variables qualitatives	20

- **Plage temporelle des données**

Les données analysées couvrent la période de 2019 à 2023.

- **Premières observations**

La structure du dataset est calquée sur la précédente concernant les ventes. Nous ne retrouvons plus les champs calculés et le champ **"prix_m2_vente"**.

Les champs **"prix_bien"** et **"surface"** pourraient servir à calculer une variable cible **"prix_m2_location"**.

Les valeurs ne sont ni normalisées, ni standardisées et devront l'être dans la prochaine étape de pré-processing

Les noms des colonnes pourraient être homogénéisée (snake_case)

Le nombre de données concernant la location est plus important en 2020 et en 2022 que les autres années.

Les identifiants sont une concaténation du nom de l'agence et d'un identifiant unique.

Le champ DEP comporte plusieurs départements (68, 69, 75, 86, 6, 14)

- **Corrélations potentielles**

Il semble avoir une corrélation entre les champs **"surface"** et **"nb_pieces"**.

- **Disponibilité des variables**

Disponibilité variable	Nombre de variables	Exemples
Variables disponibles à 100%	28	type_annonceur, typedebien, etage
Variables disponibles entre 50% et 100%	7	duree_int, logement_neuf
Variables disponibles entre 25% et 50%	5	nb_toilettes, places_parking
Variables disponibles entre 0% et 25%	11	charges_copro, parking
total	51	

- **Type des variables**

type variable	Nombre de variables	Exemples
float	16	prix_maison, prix_terrain
integer	15	bain, balcon
object	21	annonce_exclusive, ascenseur, cave
total	51	

- **Gestion des NAs**

Actions	Concernées	Exemples
Rien à faire	variables sans NA	
Supprimer la colonne	variables int/flt avec taux de NA $\leq$ X%	
imputation (moyenne, médiane)	variables int/flt avec taux de NA $>$ X%	
création d'une catégorie missing	variables catégorielles	

Dataset valeurs foncières (data-gouv)

nombre de lignes	20 195 667
nombre de colonnes	40
nombre de doublons	1 302 023
manquants (%)	49.06
nombre de variables quantitatives	17
nombre de variables qualitatives	23

- **Plage temporelle des données**

Les données analysées couvrent la période de 2019 à 2024.

- **Premières observations**

Dans les sources de data-gouv il n'y a rien concernant des datasets pour le département 68 relatif à nos deux précédents jeux de données.

La volumétrie de ce dataset est relativement importante. Un merge des différences données est nécessaire car elles sont réparties en différentes sections (années, départements, communes). Pour avoir une analyse temporelle de l'évolution des valeurs foncières de ces dernières années, nous fusionnons l'ensemble des données de cette source dans un dataset global.

Une optimisation de ce dataset est nécessaire pour pouvoir pallier aux ressources matérielles.

La variable cible est le champ "**valeur_fonciere**".

Les valeurs ne sont ni normalisées, ni standardisées et devront l'être dans la prochaine étape de pré-processing

Le code postal ne comporte pas un format classique français avec 5 caractères (float)

- **Corrélations potentielles**

Il semble avoir une corrélation avec les variables numériques "**lot3_surface_carrez**", "**lot5_numero**", "**lot2_surface_carrez**".

- **Terminologies**

Le code FANTOIR facilite la gestion des adresses et leur standardisation à l'échelle nationale.

WGS-84 est le système de référence utilisé dans les GPS (Global Positioning System), ce qui en fait une norme incontournable pour la géolocalisation et la cartographie.



Une vente par adjudication est une vente d'un bien immobilier qui se déroule aux enchères publiques.

- **Disponibilité des variables**



Disponibilité variable	Nombre de variables	Exemples
Variables disponibles à 100%	9	id_mutation, id_parcelle, code_departement, code_commune, nature_mutation
Variables disponibles entre 50% et 100%	10	nature_culture, surface_terrain, adresse_numero
Variables disponibles entre 25% et 50%	5	surface_relle_bati, lot1_numero, lot2_numero
Variables disponibles entre 0% et 25%	16	ancien_nom_commune, ancien_id_parcelle, lot5_surface_carrez
total	41	

Data Visualisations - annonces ventes et locations 68

- **Dataset ventes** → **Lien vers graphes Plotly** : [🔗 dataviz_sales_68.ipynb](#)



On peut noter que la variable “**prix_bien**” n'est pas totalement corrélée avec “**prix_maison**” et “**prix_terrain**”. Étant donné le grand nombre de valeurs manquantes de ces deux variables, cela n'est pas étonnant. Il y a logiquement une forte corrélation entre “**prix_bien**” et “**surface**”, mais également avec “**nb_pieces**” et “**nb_toilettes**”, malgré pas mal de valeurs manquantes pour cette dernière variable. La corrélation moyenne de “**prix_bien**” avec “**prix_m2_vente**” peut éventuellement découler d'une forte disparité entre les prix de vente et une plus grande homogénéité des prix au m², ou inversement.



On peut noter une forte forte disparité de prix entre maisons et appartements, ainsi qu'entre les biens neufs et anciens. Pour les maisons anciennes, on observe que le premier quartile (248K€) est supérieur au troisième quartile des appartements anciens (236K€), là où le prix des maison et appartements neufs sont bien plus ramassés, avec un prix bas plus élevé que dans l'ancien et des valeurs hautes n'excédant pas 730K€.

Médianes des prix (€) :

Maison ancienne : 325,000

Maison neuve : 282,427

Appartement ancien : 168,000

Appartement neuf : 225,950

Test global Kruskal-Wallis : p-value = 0.0000

Tests pair-à-pair :



Maison ancien vs neuf: p = 0.0000 → Il y a une différence significative

Appartement ancien vs neuf: p = 0.0000 → Il y a une différence significative

Maison ancien vs Appartement ancien: p = 0.0000 → Il y a une différence significative


Maison neuf vs Appartement neuf: p = 0.0000 → Il y a une différence significative

Il apparaît une différence significative entre le prix des biens selon qu'il s'agisse d'une maison ou d'un appartement mais également selon que le bien est neuf ou ancien. Il serait donc pertinent de distinguer ces variables dans le dataset afin d'entraîner le modèle de machine learning pour mieux prédire le prix d'un bien selon sa nature et son ancienneté.



On peut noter que contrairement à la distribution des prix de vente qui se caractérise par de fortes disparités entre maisons et appartements, ainsi qu'entre neuf et ancien, la médiane du prix de vente au m² est beaucoup plus homogène ($m = 2676\text{€}$, $ma = 2650\text{€}$, $a = 2387\text{€}$), exceptée pour les appartements neufs qui semblent être nettement plus chers que les autres biens ($an = 3356\text{€}$). Les hypothèses qui pourraient expliquer cette différence pour les appartements neufs sont à chercher du côté des variables de surface, de localisation, de prestations ("nb_toilettes", "balcon", "ascenseur", "parking", etc.)


Évolution du prix médian et du prix de vente au m² médian des biens entre février 2019 et avril 2023



On peut noter une indisponibilité a priori des données concernant les prix de vente et des prix de vente au m² pour les maisons anciennes au-delà de juillet 2020. À voir comment pallier ce manque de données. Ces données manquantes pourraient éventuellement expliquer le niveau plus élevé du prix au m² des appartements neufs par rapport aux maisons neuves dans le graphique précédent. On note en effet que les courbes démarrent sensiblement au même niveau.

- Évolution de 200K à 300K pour prix de vente médian global sur la période.
- Baisse de 3K à 2K avant remontée vers 3K pour le prix au m².

Distribution de la surface des maisons et appartements, neufs et anciens dans le Haut-Rhin



Médianes des surfaces (m²) :

Maison ancienne : 124.0 m²

Maison neuve : 106.0 m²

Appartement ancien : 72.0 m²

Appartement neuf : 69.0 m²

Test global Kruskal-Wallis : p-value = 0.0000

Tests pair-à-pair :


Maison ancien vs neuf: p = 0.0000 → Il y a une différence significative

Appartement ancien vs neuf: p = 0.0001 → Il y a une différence significative

Maison ancien vs Appartement ancien: p = 0.0000 → Il y a une différence significative

Maison neuf vs Appartement neuf: p = 0.0000 → Il y a une différence significative

Comme pour le test concernant le prix de vente, celui concernant les surfaces fait ressortir la même différence selon que le bien est neuf ou ancien et qu'il s'agisse d'une maison ou d'un appartement. La médiane de chaque catégorie serait un élément de base pertinent pour entraîner un modèle pour la prédiction des prix futurs.




On peut noter que les appartements sont plus homogènes en surface et prix, les maisons présentant plus de variabilité, ce qui pourrait être lié à la diversité des zones géographiques (urbain/rural) ou des caractéristiques uniques (piscine, dépendances, terrain, etc.).

On peut également noter que, contrairement à la surface habitable (maison/appart), la surface de terrain n'a pas d'effet linéaire évident sur le prix total. On peut formuler plusieurs hypothèses à ce résultat :


- Soit un certain nombre de données erronées faussent le résultat de la répartition.
- Soit au-delà d'un certain seuil (ex. > 2000 m²), la surface du terrain n'ajoute pas beaucoup de valeur au bien.
- Soit les très grands terrains peuvent être non constructibles, agricoles ou peu valorisés économiquement.

On peut tester l'hypothèse des terrains agricoles avec une représentation cartographique.


Cartographie des maisons selon la surface de leurs terrains





Cartographie des maisons selon leurs prix





Cartographie des appartements selon leurs prix



- Dataset locations** → **Lien vers graphes Plotly** : [🔗 dataviz_rents_68.ipynb](#)



Hormis la présence de nombreux NAs pour des variables entières, on note de fortes corrélations entre des variables qui peuvent être en doublons, notamment pour les codes “DEP”, “GRD_QUART”, “Code_IRIS” et “INSEE_COM”, ainsi que pour “mapCoordonneesLongitude” et “UU2010”. Il faudra sans doute sélectionner l'un de ces codes pour assembler les dataset entre eux et faire correspondre des représentations cartographiques. On note logiquement une forte corrélation entre les variables “prix_bien”, “nb_piece” et “surface”.




Il y a dix fois plus d'appartements en location que de maisons. Il serait intéressant de se questionner sur l'impact de la rareté de l'offre concernant les maisons sur leur prix médian. Ce pourrait être intéressant de créer une variable "rareté relative" afin de permettre l'étude de l'impact de celle-ci sur les prix. Quant au nombre de locaux commerciaux, il est quasi nul et devrait peut-être ne pas être utilisé dans le modèle.

Prix médian - Maisons : 1,100 €
Prix médian - Appartements : 640 €

Test Mann-Whitney U (Maisons et Appartements) : p-value = 0.0000


Les deux graphiques précédents montrent une offre de location de maisons près de dix fois inférieure à celle des appartements, ainsi qu'un prix médian des maisons près de deux fois supérieur à celui des appartements. Le test statistique indique nettement cette différence. Même si l'on ne peut pas clairement dire que la rareté de l'offre de location de maison provoque un prix plus élevé, nous pouvons clairement avancer cette hypothèse et prendre en compte ce facteur lors de la réalisation d'un modèle de machine learning pour la prédiction des prix.



Ce graphique permet de voir que les prix médians et moyens sont assez proches sur les quatre années étudiées. Il faudrait voir quelle donnée serait la plus utile et pertinente pour la suite du projet :


- Une médiane peut a priori donner une bonne idée pour savoir si un bien est dans la norme selon un secteur donné, en étant moins sensible aux valeurs extrêmes. Il faudrait ici pouvoir déterminer le prix au m² pour chaque bien afin de le comparer à la médiane locale.
- La moyenne pourrait être utilisée pour détecter un marché biaisé, avec la présence de bien très élevés ou très bas.

Cartographie des locations de maisons selon leurs prix





On peut observer que les maisons dont les loyers sont les plus élevés se situent dans les agglomérations principales (Mulhouse et Colmar) mais également à la frontière Suisse, près de la ville de Bâle.



Cartographie des locations d'appartements selon leurs prix







Comme pour les maisons, on peut observer que les appartements dont les loyers sont les plus élevés se situent dans les agglomérations principales (Mulhouse et Colmar) mais également à la frontière Suisse, près de la ville de Bâle.

Data Visualisations - valeurs foncières (data-gouv)











□ Carte des prix médians au m² - France métropolitaine (0 à 4000 €)



Pre-processing

Dans le cadre de ce projet, nous avons choisi de concentrer notre travail sur deux des trois jeux de données disponibles, en nous focalisant exclusivement sur les données relatives aux ventes immobilières. Le dataset des locations a été écarté car il ne répond pas directement aux objectifs centraux du projet qui sont la prédiction de l'évolution des prix de vente et l'estimation du prix au m² des biens immobiliers.

Un travail de preprocessing a été mené sur les deux jeux de données conservés :

- Le fichier des ventes issues de la base DVF (Demande de Valeur Foncière) fourni par data.gouv.fr
- Le jeu de données d'annonces de ventes immobilières dans le département du Haut-Rhin (68), issu d'un partenaire externe

Ces deux sources ont ensuite été fusionnées sur la base de variables communes (localisation, type de bien, etc.), afin de constituer un dataset enrichi, combinant données déclaratives officielles et données issues du marché (annonces), pour une modélisation plus robuste et contextuelle des prix.

- **Dataset Vente immobilières 68**

Colonne	Valeur	Remarque
type_annonceur	colonne à supprimer	1 seule modalité
surface_terrain	0	Mettre 0 si la surface terrain et le prix_terrain est NaN. Il restera 1 seule valeur avec une surface Nan et prix_terrain à 1.0
prix_maison	0	Mettre 0 si le type de bien est "a" ou "an". Prendre le prix médian du quartier
prix_terrain	0	Mettre 0 si la surface terrain et le prix_terrain est NaN. Prendre le prix médian du quartier
dpeC	0	Mettre 0 si le dpeL est vierge, non spécifié ou à 0
nb_etage	0	Mettre 0 si la valeur "etage" est à 0
parking	colonne à supprimer	99.% de manquants
places_parking	colonne à supprimer	63.34 % de manquants et pas d'infos pertinentes pour imputer

cave	False	On peut partir du principe que si la cave n'est pas renseignée alors il n'y en a pas.
ges_class	NS	Mettre non spécifié si le dpeC est NaN.
annee_construction	mediane	Mettre la médiane de l'année de construction par quartier (GRD_QUART)
nb_toilettes	1	Modalité la plus fréquente
nb Terraces	0	On peut partir du principe que si le nombre de terrasse n'est pas renseigné alors il n'y en a pas.
videophone	0	0 si non renseigné
porte_digicode	0	0 si non renseigné
ascenseur	False / True	On peut partir du principe qu'un bien avec plus de 7 étages dispose d'un ascenseur
surface_balcon	colonne à supprimer	97.63 % de manquants
nb_logements_copro	0	0 si non renseigné
charges_copro	colonne à supprimer	75.93 % de manquants, valeurs qui pourraient être renseignées à posteriori (ex régulation 1 fois par an)
chauffage_energie	NS / Chauffage systeme	Récupération valeur Chauffage système ou Création nouvelle modalité Non Spécifié
chauffage_systeme	NS / Chauffage energie	Récupération valeur Chauffage énergie ou Création nouvelle modalité Non Spécifié pour les NaN
chauffage_mode	NS	Création nouvelle modalité Non Spécifié
logement_neuf	0/1	Changer le type en int, 1 pour les types de bien "an" et "mn", 0 sinon
duree_int	colonne à supprimer	Colonne difficile à interpréter, qui pourraient être renseignées à posteriori (calcul logiciel)
loyer_m2_median_n6	colonne à supprimer	Les ids du dataset de location ne semblent pas se retrouver dans le dataset ventes

nb_log_n6	colonne à supprimer	Les ids du dataset de location ne semblent pas se retrouver dans le dataset ventes
taux_rendement_n6	colonne à supprimer	Les ids du dataset de location ne semblent pas se retrouver dans le dataset ventes
loyer_m2_median_n7	colonne à supprimer	Les ids du dataset de location ne semblent pas se retrouver dans le dataset ventes
nb_log_n7	colonne à supprimer	Les ids du dataset de location ne semblent pas se retrouver dans le dataset ventes
taux_rendement_n7	colonne à supprimer	Les ids du dataset de location ne semblent pas se retrouver dans le dataset ventes

- **Dataset valeurs foncières (data-gouv)**

Colonne	Valeur	Remarque
ancien_code_commune	colonne à supprimer	99,99 % de manquants
ancien_nom_commune	colonne à supprimer	99,99 % de manquants
ancien_id_parcelle	colonne à supprimer	100 % de manquants
numero_volume	colonne à supprimer	99,76 de manquants
adresse_suffixe	colonne à supprimer	ne semble pas corrélér avec notre target
adresse_numero	colonne à supprimer	pas de corrélation avec notre target
valeur_fonciere	lignes NaN à supprimer	Faible % de NaN < 1%
adresse_nom_voie	création nouvelles modalités (ex: en cours, NS)	La plupart des lignes correspondent à la nature "Vente en l'état futur d'achèvement". Création d'une nouvelle modalité en cours et pour les autres, une modalité Non Spécifié
adresse_code_voie	création nouvelles modalités (ex: en cours, NS)	La plupart des lignes correspondent à la nature "Vente en l'état futur d'achèvement". Création d'une

		nouvelle modalité en cours et pour les autres, une modalité Non Spécifié
lot1_numero	valeur id_parcelle	La valeur d'id parcelle semble pouvoir renseigner lot1_numero
lot1_surface_carrez	surface_reelle_bati	la valeur est très proche de la variable "surface_reelle_bati"
lot2_numero	0	Pas de valeur manquante avec un nombre de lot à 2. Création d'une valeur 0 pour les nombres de lots < 2 et lot2_numero à NaN
lot2_surface_carrez	Suppression lignes	Difficile d'imputer une valeur ici
lot3_numero	0	Pas de valeur manquante avec un nombre de lot à 3. Création d'une valeur 0 pour les nombres de lots < 3 et lot3_numero à NaN
lot3_surface_carrez	Suppression lignes	Difficile d'imputer une valeur ici
lot4_numero	0	Pas de valeur manquante avec un nombre de lot à 4. Création d'une valeur 0 pour les nombres de lots < 4 et lot4_numero à NaN
lot4_surface_carrez	Suppression lignes	Difficile d'imputer une valeur ici
lot5_numero	0	Pas de valeur manquante avec un nombre de lot à 5. Création d'une valeur 0 pour les nombres de lots < 5 et lot5_numero à NaN
lot5_surface_carrez	Suppression lignes	Difficile d'imputer une valeur ici
code_type_local	0	Création d'un nouveau code 0. Le code type local peut être déterminé avec le type local si il n'est pas NaN aussi.
type_local	Autre	Création d'une nouvelle modalité si le code type local et type local est NaN. Sinon détermination du type par rapport au code
surface_reelle_bati	0	Mettre 0 si la nature culture concerne des prés, sols, futaies etc.
nombre_pieces_principales	0	Mettre 0 si la nature culture

		concerne des prés, sols, futaies etc.
code_nature_culture	NS	Création nouvelle modalité Non Spécifié
nature_culture	Non Spécifié	Création nouvelle modalité Non Spécifié
code_nature_culture_speciale	NS	Création nouvelle modalité Non Spécifié
nature_culture_speciale	Autre	Création nouvelle modalité autre
surface_terrain	0	On peut partir du principe qu'il n'y a pas de terrain pour certains appartements ou maisons si NaN.
longitude	lignes à supprimer	Les longitudes manquantes semblent être regroupées par adresse et par nature de culture < 0.25 %
latitude	lignes à supprimer	Les latitudes manquantes semblent être regroupées par adresse et par nature de culture < 0.25 %

Modélisation

Dans ce projet, la problématique se définit clairement comme un problème de régression supervisée, dans la mesure où l'objectif principal est de prédire une variable continue : le prix au mètre carré d'un bien immobilier.

La tâche assignée au modèle est d'ordre prédictif mais également décisionnelle, puisqu'il s'agit de fournir une aide à l'évaluation de marché ou à la prise de décision d'achat. Concrètement, l'utilisateur doit être en mesure d'obtenir une estimation de prix fiable en renseignant dans une interface applicative (type Streamlit) certaines caractéristiques du bien, telles que la surface, la localisation (commune ou département), et potentiellement d'autres attributs structurels ou contextuels.

Pour évaluer la performance des modèles, plusieurs métriques de régression ont été sélectionnées de manière complémentaire :

- Le coefficient de détermination R^2 est retenu comme indicateur principal car il offre une mesure globale de la qualité des prédictions par rapport à la variance totale des données observées.
- La MAE permet une interprétation intuitive de l'erreur moyenne, exprimée en euros, et est donc particulièrement utile pour une communication métier ou utilisateur final.
- La RMSE est également prise en compte comme métrique complémentaire à la MAE. Elle représente la racine carrée de l'erreur quadratique moyenne, ce qui permet d'exprimer l'erreur moyenne dans la même unité que la variable cible (ici, en euros par mètre carré). Contrairement à la MAE qui accorde le même poids à toutes les erreurs, la RMSE accentue l'impact des grandes erreurs tout en conservant une échelle directement interprétable. Elle constitue ainsi un bon compromis pour détecter les écarts importants tout en conservant une lisibilité métier.
- La MSE est également utilisée dans l'évaluation de certains modèles pour détecter et quantifier l'impact d'erreurs importantes, souvent liées à des valeurs aberrantes ou atypiques (outliers), du fait de son caractère pénalisant envers les erreurs élevées.

Ce choix méthodologique assure une évaluation équilibrée entre précision moyenne, robustesse aux extrêmes et capacité explicative.

Modélisation du prix de vente au m²

Dans le cadre de la modélisation, nous avons fait le choix de conserver uniquement les données de l'année 2024 en tant que jeu de test pour évaluer les performances de prédiction sur les données les plus récentes. Cette approche vise à simuler un scénario de production réaliste, où l'on cherche à prédire des prix à venir à partir d'un historique de transactions.

Sans surprise, les modèles de régression linéaire classiques (comme la régression simple, Lasso ou Ridge) se sont révélés moins performants, en raison de leur capacité limitée à capturer les non-linéarités complexes présentes dans les données immobilières.

À l'inverse, les modèles ensemblistes, et notamment ceux reposant sur des techniques de bagging ou de boosting, se sont montrés nettement plus performants. En particulier, l'algorithme XGBoost, offre de meilleurs résultats en matière de R^2 et d'erreur moyenne que les modèles régularisés. Une optimisation des hyperparamètres par recherche aléatoire (RandomizedSearchCV) a été mise en place pour ces modèles, dans l'objectif d'atteindre un compromis optimal entre biais et variance.


Parallèlement, la réduction de dimension par PCA a été testée mais n'a pas permis d'amélioration significative des performances. Même en testant différentes échelles de composants (de 2 à 30), les scores obtenus sont restés stables, ce qui suggère que les dimensions initiales sont déjà pertinentes et bien encodées. Cette piste pourra toutefois être approfondie dans un cadre d'optimisation du temps de calcul ou de simplification du modèle pour des cas d'usage spécifiques.

Enfin, il convient de souligner que les modèles ensemblistes, bien qu'efficaces en termes de performance, présentent des limitations en matière de généralisation lorsqu'ils ne sont pas suffisamment régularisés, ce qui peut conduire à un overfitting. De plus, leur taille mémoire importante complexifie le versioning et le déploiement dans un environnement de production.

- **Réduction de dimension pour les modèles GradientBoosting et XGBoost :**

Modèle	Composants	MAE Train	RMSE Train	R2 train	MAE test	RMSE Test	R2 test	Overfit
GradientBoosting	2	6718.33	65502.96	0.1780	6509.13	58424.71	0.1965	non
XGBoost	2	6634.21	65849.80	0.1693	6444.81	59081.07	0.1783	non
GradientBoosting	3	5150.26	64256.77	0.2090	4991.29	57521.17	0.2211	non
XGBoost	3	4952.41	63929.08	0.2171	4819.08	57272.92	0.2278	non
GradientBoosting	5	4369.32	59007.22	0.3330	4248.38	54346.15	0.3047	non
XGBoost	5	3856.17	57732.53	0.3615	3802.20	54122.74	0.3104	non
GradientBoosting	10	4031.85	51062.28	0.5005	4008.03	50111.91	0.4089	non
XGBoost	10	2943.25	37132.92	0.7359	3258.64	47842.57	0.4612	non
GradientBoosting	20	3627.91	46576.45	0.5844	3704.41	47716.85	0.4640	non
XGBoost	20	2514.93	31169.63	0.8139	3001.13	47541.37	0.4680	non
GradientBoosting	30	3671.76	45179.59	0.6090	3744.63	46872.95	0.4828	non
XGBoost	30	2418.00	28407.35	0.8454	2938.82	46992.28	0.4802	non
GradientBoosting	0.95%	4267.22	57880.28	0.3582	4127.89	52265.44	0.3570	non
XGBoost	0.95%	3512.43	53054.21	0.4608	3537.62	51072.64	0.3860	non


- **Sélection de features :**



[Résultats GradientBoosting]

Train - MAE: 5625.42 | RMSE: 54176.94 | R^2 : 0.4377

Test - MAE: 5591.44 | RMSE: 49622.61 | R^2 : 0.4204



[Résultats XGBoost]


Train - MAE: 4821.20 | RMSE: 42450.29 | R^2 : 0.6548

Test - MAE: 5063.76 | RMSE: 46696.27 | R^2 : 0.4867

→ La sélection de features n'offre toujours pas de résultats acceptables.

- **Test Bagging / Stacking**


Le test a été effectué sur les modèles **Gradient Boosting**, et **XGBoost**.



[Résultats bagging]

Train - MAE: 659.18 | RMSE: 13685.79 | R^2 : 0.9641

Test - MAE: 811.85 | RMSE: 22966.10 | R^2 : 0.8758



[Résultats stacking]


Train - MAE: 869.30 | RMSE: 13543.81 | R^2 : 0.9649

Test - MAE: 973.76 | RMSE: 20361.14 | R^2 : 0.9024

→ **Les résultats sont nettement meilleurs qu'avec une réduction de dimension. Le stacking est plutôt performant.**


- Tests d'autres modèles :

Des tests ont été effectués sur les modèles **CatBoostRegressor** et **LightGBM** qui sont plus rapides que GradientBoost.



MAE: 974.7841793455226 | RMSE: 16712.52987906085 | R^2 : 0.934250736468181

→ L'avantage de CatBoost est qu'il propose un paramètre permettant un early stopping.



[Résultats lightgbm]


Train - MAE: 757.43 | RMSE: 11169.46 | R^2 : 0.9761

Test - MAE: 894.20 | RMSE: 18589.37 | R^2 : 0.9187

Les résultats sont satisfaisants dans l'ensemble. ces modèles sont performants.

- **Voting Regressor**

Les estimateurs choisis pour le voting sont les modèles **CatBoost**, **LightGBM** et **XGBoost**.




[Résultats Voting_CatBoost_LightGBM_XGBoost]
 Train - MAE: 871.33 | RMSE: 14259.16 | R²: 0.9610
 Test - MAE: 931.01 | RMSE: 17923.62 | R²: 0.9244

→ La combinaison de modèles permet d'avoir de belles performances. Le modèle Voting Regressor pourrait répondre à notre problématique.

Interprétation des modèles


- **CatBoost**

	Feature	Mean SHAP Value
1	valeur_fonciere	13635.527489
20	surface_terrain	10056.324208
5	lot1_surface_carrez	6486.161430
16	surface_reelle_bati	6253.943871
2	code_commune	408.509481
3	code_departement	322.980746
24	mois	292.611660
25	type_local_Appartement	271.400224
17	nombre_pieces_principales	240.323609
22	latitude	208.621852
21	longitude	150.230740
15	code_type_local	123.379368
28	type_local_Local industriel, commercial ou ass...	119.890700
18	code_nature_culture	106.187698
27	type_local_Dépendance	54.819689
0	numero_disposition	49.015629
19	code_nature_culture_speciale	14.058389
26	type_local_Autre	11.458016
34	nature_mutation_Vente en l'état futur d'achève...	10.674036
7	lot2_surface_carrez	1.897333




- LightGBM

	Feature	Mean SHAP Value
20	surface_terrain	11240.623496
5	lot1_surface_carrez	9871.989759
1	valeur_fonciere	9599.582038
17	nombre_pieces_principales	1688.245632
18	code_nature_culture	1634.883528
25	type_local_Appartement	1319.568230
15	code_type_local	594.838583
2	code_commune	421.977595
3	code_departement	256.029395
22	latitude	192.601583
24	mois	187.782855
14	nombre_lots	141.608252
21	longitude	137.539459
27	type_local_Dépendance	108.352595
28	type_local_Local industriel, commercial ou ass...	105.142326
34	nature_mutation_Vente en l'état futur d'achève...	24.081849
19	code_nature_culture_speciale	23.449397
0	numero_disposition	7.792340
31	nature_mutation_Echange	5.880115
29	type_local_Maison	3.427865
33	nature_mutation_Vente	2.941160
7	lot2_surface_carrez	0.784077
9	lot3_surface_carrez	0.402618
35	nature_mutation_Vente terrain à bâtir	0.089459



- **XGBoost**

	Feature	Mean SHAP Value
5	lot1_surface_carrez	13665.892578
20	surface_terrain	11984.018555
1	valeur_fonciere	11302.141602
15	code_type_local	5234.028320
17	nombre_pieces_principales	3031.168945
18	code_nature_culture	2629.237305
25	type_local_Appartement	2390.287598
3	code_departement	543.258789
14	nombre_lots	494.844604
21	longitude	484.728699
28	type_local_Local industriel, commercial ou ass...	415.531952
27	type_local_Dépendance	339.901459
22	latitude	333.494568
2	code_commune	319.185547
24	mois	223.231644
7	lot2_surface_carrez	79.572388
0	numero_disposition	77.142990
34	nature_mutation_Vente en l'état futur d'achève...	20.522518
19	code_nature_culture_speciale	6.975384
31	nature_mutation_Echange	3.058770
33	nature_mutation_Vente	2.866542
30	nature_mutation_Adjudication	0.078403
9	lot3_surface_carrez	0.074220
11	lot4_surface_carrez	0.059802
35	nature_mutation_Vente terrain à bâtir	0.033714
13	lot5_surface_carrez	0.025791
12	lot5_numero	0.004629




- **Exemple de prédiction :**

```
data = {
    'code_commune': 75056,
    'code_departement': 75,
    'type_local': 'Appartement',
    'nature_mutation': 'Vente',
    'lot1_surface_carrez': 50,
    'nombre_pieces_principales': 3,
    'surface_terrain': 0
}
```

→ Estimation du prix au m² : 10863.0 €

→ Estimation valeur foncière : 543150.0 €



On remarque que les modèles ne prennent pas en compte les variables “lot_n_numero”. La variable “surface_reelle_bati” n’est pas exploitée dans les modèles LightGBM et XGBoost. La variable utilisée à la place est “lot_1_surface_carrez”.

Un StackingRegressor en plus du VotingRegressor n’apporte pas d’amélioration.

[Résultats StackingRegressor_opt_2.pkl]
Train - MAE: 1303.29 | RMSE: 17863.52 | R²: 0.9389
Test - MAE: 1341.57 | RMSE: 20293.06 | R²: 0.9031

Notre modèle le plus performant est le Voting Regressor.

[Résultats Voting_CatBoost_LightGBM_XGBoost]
Train - MAE: 871.33 | RMSE: 14259.16 | R²: 0.9610
Test - MAE: 931.01 | RMSE: 17923.62 | R²: 0.9244

Le modèle présente une MAE de 871 € par m² sur l’ensemble d’entraînement, et de 931 € par m² sur les données de test. Ce niveau d’écart est globalement cohérent avec les attentes du domaine, bien que certaines prédictions s’éloignent davantage de la réalité, comme l’indique la valeur du RMSE, qui souligne la présence de certaines erreurs importantes (outliers).

En termes de pouvoir explicatif, le modèle atteint un coefficient de détermination R² de 96,1 % sur les données d’apprentissage, et 92,4 % sur les données jamais vues. Cela indique qu’il parvient à expliquer la majorité de la variance des prix au m², tout en conservant une bonne capacité de généralisation sur de nouvelles observations.

- **Deep Learning**

Une expérimentation a été conduite avec un Perceptron Multi-Couche (MLP) afin de comparer ses performances à celles des modèles de machine learning précédemment testés.

Les résultats obtenus sont corrects dès les premières itérations, sans recourir à des réglages poussés. Cependant, les tentatives d’optimisation plus approfondies se sont révélées coûteuses en temps de calcul, sans conduire à des améliorations significatives en termes de performance.


Même après plusieurs heures d’entraînement, le modèle MLP reste inférieur à des approches plus classiques, telles que les modèles ensemblistes, notamment le Voting Regressor, qui s’avèrent à la fois plus efficaces et plus stables.

En conséquence, cette approche par réseau de neurones ne sera pas retenue dans la suite du projet, au regard de son rapport performance/complexité peu favorable.

Modèle	MAE Train	MAE test	RMSE Train	RMSE Test	R2 Train	R2 Test
MLP	2060.83951	2003.268778	35417.293283	33382.746608	0.7597	0.737668
MLP optimisé	2312.071636	2232.100046	36790.455673	33704.551979	0.740705	0.732586

- **Essais avec modification des variables**

L'analyse des valeurs SHAP a permis d'identifier les variables les plus influentes dans les modèles ensemblistes. La variable "**valeur_fonciere**", fortement corrélée à la cible, apparaît de manière récurrente aux 1re et 3e positions parmi les features les plus importantes dans les modèles CatBoost, LightGBM et XGBoost. Afin d'évaluer le degré de dépendance des modèles à cette variable, une série de tests a été conduite en l'excluant du jeu de données, pour en mesurer l'impact sur la performance globale.



Modèle	R ²	MAE (€/m ²)	MSE (€/m ²) ²
Linear Regression	0.227	1225.27	4 043 982.66
Decision Tree	0.348	842.73	3 412 241.22
Random Forest	0.651	638.67	1 826 567.41
Gradient Boosting	0.476	910.06	2 741 449.41
KNN	0.595	693.03	2 117 026.55

Le modèle Random Forest domine sur les 3 métriques : meilleur R^2 (0.651), plus faible MAE et MSE. Le KNN arrive à un bon compromis entre performance ($R^2 = 0.595$) et erreur modérée, sans optimisation complexe. Le Gradient Boosting est meilleur que les modèles linéaires, mais moins bon que Random Forest et KNN ici → potentiellement améliorable avec optimisation. Le modèle de Linear Regression est en difficulté avec une mauvaise adaptation aux non-linéarités → R^2 le plus faible et MAE le plus élevé. Enfin, le Decision Tree est meilleur que la régression linéaire, mais souffre d'overfitting probable sans régularisation.

Après optimisation du modèle Random Forest via RandomizedSearchCV, nous obtenons un score R^2 quasiment identique avec les paramètres suivants :

- Meilleurs paramètres trouvés : {'max_depth': 28, 'max_features': 'sqrt', 'min_samples_leaf': 2, 'min_samples_split': 3, 'n_estimators': 241}
- Meilleur score R^2 (CV) : 0.654

→ Les hyperparamètres trouvés semblent permettre une représentation fine sans overfitting.

Voici les résultats sur set de test avec les meilleurs paramètres optimisés :

R^2 (test) : 0.659

MAE : 633.12

MSE : 1781558.05

→ Cela démontre une bonne capacité explicative avec une MAE acceptable pour des données immobilières, pour lesquelles la variance est souvent très élevée.

Voici les résultats avec les 10 meilleures features :

R^2 (top 10 features) : 0.660

Voici les résultats avec les 5 meilleures features :

R^2 (top 5 features) : 0.653

Il n'y a aucune perte de performance en ne gardant que les 10 variables les plus importantes. En réduisant au top 5 features, la perte est minime, ce qui prouve que le modèle est peu dépendant de variables faibles.

L'importance concentrée sur peu de variables pourrait permettre de simplifier le modèle pour le déploiement (moins de features à collecter). Le fait que les Top 5-10 variables suffisent est idéal pour une app Streamlit où le but est de limiter les inputs utilisateur.

Les résultats étant bien moins performants que ceux obtenus avec le VotingRegressor sur le jeu complet, et par manque de temps dans le cadre de cet exercice, nous laisserons de côté l'option de mener plus d'essai avec le jeu de données amputé de la variable "valeur_fonciere".

Modélisation de l'évolution du prix de vente

Dans le cadre de l'analyse temporelle, nous avons choisi de nous appuyer sur le prix au mètre carré plutôt que sur la valeur foncière brute, afin de mieux refléter les dynamiques du marché immobilier, indépendamment de la taille ou de la nature des biens. Cette métrique est plus représentative des tendances territoriales, notamment lorsqu'on compare des zones aux typologies variées.


En raison de contraintes computationnelles, l'ensemble du jeu de données national (près de 20 millions de lignes) n'a pas été exploité en totalité. Par ailleurs, une moyenne à l'échelle nationale aurait une valeur analytique limitée, les fortes disparités entre zones urbaines et rurales risquant de masquer les dynamiques locales. Pour illustrer la méthodologie, nous avons donc restreint l'analyse au département de Paris (75).

L'examen graphique de la série temporelle ne permet pas de conclure clairement à un comportement additif ou multiplicatif. Cette ambiguïté peut s'expliquer par les fluctuations atypiques liées à la période Covid (hausse des ventes), suivies d'un ralentissement marqué. Une analyse statistique via les écarts types confirme néanmoins que la série est de nature multiplicative.


Cela implique la nécessité d'une transformation logarithmique afin de rendre la série additive, condition préalable pour l'application de certains modèles classiques de séries temporelles tels que ARMA, ARIMA ou SARIMA.

L'analyse des fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (PACF) ne révèle pas de saisonnalité marquée, ce qui complique l'identification de patterns stables à exploiter par les modèles.


Un test exploratoire avec une régression linéaire simple confirme qu'en réduisant la granularité de la prédiction à des niveaux fins (commune ou quartier), la performance du modèle devient rapidement insatisfaisante. Une approche alternative pourrait consister à prédire des intervalles de confiance, ou à fournir une fourchette de prix plutôt qu'une estimation unique, pour mieux refléter l'incertitude.




Avant transformation




Après transformation




Comparaison des valeurs réelles et des prédictions



Autocorrelation



Partial Autocorrelation



Modèle	MAE	RMSE	R ²
ARIMA	0.44571	0.549795	-0.054587
ARIMA	0.448625	0.551821	-0.062373
ARIMA	0.486898	0.57003	-0.133643
Prophet	183908.40	223254.16	-0.98
Prophet	166951.021819	211556.044537	-0.774437
GRU	283360.206198	1.212434e+06	0.009431
LSTM	331196.593762	1.207558e+06	0.017383
GRU Optimisé	344284.385838	1.419728e+06	-0.358247
LSTM Optimisé	344284.385838	1.419728e+06	-0.358247
TCN (Robust scaler)	2582.952873	15004.88812	0.161125
RNN (Robust scaler)	126459.016422	174482.246974	0.371986

Les premières expérimentations menées avec le modèle ARIMA n'ont pas permis de capturer adéquatement les fluctuations du marché immobilier. Les dynamiques non linéaires, les effets exogènes et la faible stationnarité apparente de la série compliquent la modélisation avec ce type d'approche.

Le modèle Prophet, bien que conçu pour intégrer automatiquement les tendances et les effets saisonniers, n'atteint pas un niveau de performance satisfaisant. Malgré plusieurs tentatives d'optimisation, les améliorations restent limitées au regard du coût computationnel et sans garantie de convergence vers un résultat plus robuste.

De manière générale, les performances obtenues avec les différents modèles testés restent en deçà des attentes. Le recours aux modèles séquentiels de deep learning (RNN, GRU, LSTM) s'est imposé comme une piste prioritaire d'exploration. Cependant, même avec ces architectures, les résultats restent modestes, avec un R² plafonnant entre 0.30 et 0.38, malgré de nombreux essais et ajustements.

Ces constats suggèrent que la limitation ne réside pas uniquement dans le choix des modèles, mais plutôt dans la méthodologie globale ou la qualité des données disponibles. À ce stade, il est difficile d'isoler avec certitude les facteurs de défaillance. Une part importante du travail a été consacrée au nettoyage, à la structuration et à l'enrichissement des données, mais cela n'a pas suffi à obtenir des résultats statistiquement satisfaisants.

Un effort a été fait pour enrichir les données temporelles, en intégrant notamment :

- Le taux d'inflation mensuel des quatre dernières années,
- Les taux d'intérêt du livret A,
- Les taux moyens bancaires annuels.

Concernant la standardisation des variables, plusieurs méthodes ont été comparées (StandardScaler, MinMaxScaler, RobustScaler). C'est RobustScaler qui semble offrir les performances les plus stables, en particulier sur des séries sujettes aux outliers.

Les tests d'ajout de couches, de variation des fonctions d'activation (tanh, relu) et de recherche d'hyper paramètres n'ont pas permis d'améliorer significativement les performances.

À ce jour, le modèle le plus performant pour la prédiction temporelle est un RNN combinant couches GRU et LSTM, avec un score R^2 de 0.372, obtenu après ajustement de l'architecture.

Limites et pistes d'amélioration

Un enrichissement plus cohérent des données aurait sans doute permis de mieux modéliser les tendances. Par exemple :

- Le dataset Ventes 68 contient des informations précieuses (diagnostics énergétiques, présence d'ascenseur, balcon, etc.) mais ne couvre pas l'année 2024.
- À l'inverse, le dataset national (data.gouv) contient bien les données de 2024, mais ne couvre pas spécifiquement le département 68.

Le merge des deux jeux de données n'a donc pas permis d'accroître la qualité prédictive du modèle, en raison d'un manque de cohérence temporelle et géographique.

Conclusion

Ce premier projet en data science a été à la fois exigeant et formateur. Malgré des résultats parfois en deçà des attentes, il nous a permis d'appréhender la complexité des données réelles et la rigueur qu'impose une démarche analytique appliquée.

Dès les premières étapes, nous avons dû structurer notre approche, tester les concepts étudiés et construire une dynamique d'équipe efficace. Les nombreuses itérations, ajustements et retours en arrière ont enrichi notre compréhension des outils et des méthodes.

La modélisation des séries temporelles représente un défi majeur, nécessitant une analyse approfondie et une grande rigueur dans le traitement des données. Les limites de performance rencontrées s'expliquent en partie par l'absence de données locales cohérentes pour 2024, des sources hétérogènes et des contraintes techniques sur le volume.

Ce projet met également en lumière l'importance capitale de la qualité des données et du preprocessing. L'intégration de sources disparates a parfois affaibli la robustesse des modèles, soulignant la nécessité d'un socle de données structuré et harmonisé.

Les travaux autour de la réduction de dimension (PCA) et l'évaluation des modèles de régression ont permis d'identifier les variables les plus déterminantes dans la prédiction du prix au m², tout en ouvrant la voie à une simplification du modèle en vue d'un déploiement futur.

Enfin, ce projet nous a appris l'importance de l'expérimentation, de la persévérance et du recul critique. Nous avons validé des modèles fiables pour la prédiction instantanée des prix, tout en identifiant des pistes claires d'amélioration pour la modélisation temporelle : meilleure harmonisation des données, intégration de variables exogènes, et exploration de méthodes probabilistes pour renforcer la précision des prévisions.

Ressources

- **Données**

Annonces de vente/location :

- https://raw.githubusercontent.com/klopstock-dviz/immo_vis/master/data/ech_annonces_ventes_68.csv
- https://raw.githubusercontent.com/klopstock-dviz/immo_vis/master/data/ech_annonces_locations_68.csv
- Prix, surface, nb de pièces, type, position géographique (France des 5 dernières années): <https://www.data.gouv.fr/fr/datasets/demandes-de-valeurs-foncieres-geolocalisees/>
- Autres données open source (Ventes DVF, Insee, Data gouv et diverses API publiques) à scraper

- **Ressource additionnelle**

Une application en lien avec le sujet :

<https://comparateur-communes.fr/>

- **Sources**

- <https://www.notaires.fr/fr/article/marche-de-limmobilier-tendances-et-evolutions-des-prix-de-limmobilier-janvier-2025>
- <https://www.insee.fr/fr/metadonnees/definition/c1523>
- <https://apimo.net/fr/api/r%C3%A9f%C3%A9rentiel/>
- <https://datafoncier.cerema.fr/dv3f>
- <https://datafoncier.cerema.fr/>
- <https://www.observatoires-des-loyers.org/decouvrir-le-reseau/publications/details/calcul-devolutions-de-loyers-a-partir-des-donnees-des-observatoires-locaux-des-loyers-methode-et-resultats>
- <https://www.insee.fr/fr/statistiques/4277733?sommaire=4318291>
- <https://monimmeuble.com/actualite/marche-locatif-2025-loyers-en-hausse-et-tensions-record-en-france>
- <https://fr.statista.com/statistiques/638753/loyer-metre-carre-immobilier-social-france-selon-region/>

- **Fichier de travail**

pour les 3 datasets :

- https://docs.google.com/spreadsheets/d/1IAR2KvRdsgmnmsPKSM8tHg_Sy6Dz4VJH/edit?gid=1032191672#gid=1032191672